

Analyse SSIM / LPIPS

Pourquoi les trois algorithmes (AKAZE, BRISK, ORB) donnent des scores quasi identiques, et comment corriger le protocole d'évaluation

Projet : Master Thesis — Alignement temporel de vidéos rail-track

Module concerné : combined_method/evaluation/

Données analysées : Plan1 / hybrid_{akaze,brisk,orb}/evaluation_*.json

1. Le constat

Les trois algorithmes de feature matching produisent des scores SSIM et LPIPS indiscernables sur Plan1 :

Métrique	AKAZE	BRISK	ORB
SSIM mean (↑)	0.3771	0.3770	0.3770
LPIPS mean (↓)	0.7133	0.7134	0.7134
SSIM max	0.4391179879506429	0.4391179879506429	0.4391179879506429
n_forward_matches	2711	2711	2711

Le SSIM max est **identique à 16 décimales** entre les trois algorithmes — c'est la signature d'un protocole où le signal de l'algorithme est noyé dans le bruit de la métrique elle-même.

2. Rappel : que mesurent vraiment SSIM et LPIPS ?

SSIM (Wang et al., 2004)

Opère sur les pixels, mais pas naïvement. Il calcule des statistiques locales (luminance, contraste, structure) sur des fenêtres glissantes 11×11 et compare ces statistiques entre les deux images. C'est **ancré dans l'espace pixel**, donc fortement sensible aux différences photométriques globales (exposition, balance des blancs, météo).

LPIPS (Zhang et al., 2018)

Ne compare **pas** les pixels. Les deux images passent dans un réseau pré-entraîné (AlexNet ou VGG) et la distance est calculée dans l'espace des features apprises. Conçu pour capturer la similarité *perceptuelle* au sens humain — donc plus tolérant aux décalages photométriques mineurs, mais toujours pénalisé quand la luminosité globale diverge fortement.

	SSIM	LPIPS
Espace de comparaison	Pixels (fenêtres 11×11)	Features de réseau (VGG/AlexNet)
Niveau d'abstraction	Bas	Haut (perceptuel)
Sensible à la lumière	Très	Modérément
Convention	Plus haut = mieux	Plus bas = mieux
Gamme typique	[-1, 1]	[0, ~1]

3. Diagnostic : trois causes de la convergence des scores

Cause #1 — Le DTW domine, le fine-tuning est marginal

Les trois algorithmes partagent la même phase coarse (DTW sur le flux optique). Le fine-tuning AKAZE/BRISK/ORB est contraint à une fenêtre stricte de $\pm search_window$ (=10) frames autour de la prédiction DTW, et tombe en fallback sur la prédiction DTW si moins de 4 inliers RANSAC sont trouvés. Résultat : les trois convergent vers des `v2_frame` très proches, voire identiques pour la plupart des frames.

Cause #2 — Les métriques mesurent surtout le gap photométrique

SSIM ≈ 0.377 et LPIPS ≈ 0.71 sont des valeurs **médiocres dans l'absolu**. Pour une vidéo de référence parfaitement alignée avec elle-même, on attendrait SSIM ≈ 1.0 et LPIPS ≈ 0 . Les deux vidéos rail filmées à des moments différents (luminosité, exposition, météo, vitesse) ont une distance inhérente très supérieure à la fluctuation que l'alignement peut introduire. La métrique est **dominée par cette distance inhérente**, le signal d'alignement s'y noie.

Démonstration empirique sur deux frames synthétiques identiques avec un décalage de luminosité de +40 sur 256 niveaux :

Configuration	SSIM
Frames identiques (sanity check)	1.0000
Frame + shift luminosité +40 (sans normalisation)	0.9622
Frame + shift luminosité +40 (avec normalisation photométrique)	1.0000

Conclusion : sur une vidéo réelle où le shift est plus complexe (gain spatial, ombres, perspective), la pénalité photométrique peut facilement faire chuter SSIM de 1.0 vers 0.4 même pour un alignement parfait.

Cause #3 — Le sampling et la déduplication biaisent la mesure

Dans `evaluate.py`, la fonction `sample_frame_pairs` applique un `seen_v2 = set()` qui rejette les paires dont le `v2_frame` a déjà été vu. Or les plateaux DTW (plusieurs `v1_frame` mappés à un même `v2_frame`) sont des données légitimes — les déduper biaise l'échantillon vers le début de chaque plateau et réduit silencieusement la taille effective de l'échantillon.

4. Améliorations implémentées

Cinq changements ont été appliqués au module `combined_method/evaluation/` en conservant la rétro-compatibilité (anciens appels et anciens scripts continuent de fonctionner).

#	Changement	Fichier	Effet
1	Normalisation photométrique (<code>SSIMMetric.py</code> , <code>lpiips/2/metric1.py</code>)	<code>histogram.py</code>	Élimine le biais dû à la différence d'éclairage entre les deux v
2	ROI mask en option (preset 'rail_lower' par défaut)	<code>SSIMMetric.py</code>	Image de mesure sur la zone discriminante (rails) plutôt q
3	SSIM en grayscale par défaut (<code>ssim_chromatic=False</code>)	<code>ssim_chromatic.py</code>	Convention canonique Wang 2004, réduit le bruit chromatiqu
4	Suppression du dedup seen_v2 (option <code>dedup_v2=False</code> par défaut)	<code>evaluation.py</code>	Conservé toutes les paires échantillonnées, y compris les pl
5	Backbone LPIPS plus visible (<code>alex_vgg</code> dans le nom de la métrique)	<code>lpiips_vgg.py</code>	Permet de switcher facilement vers VGG (plus discriminant)

Effet sur le nom des métriques (auto-documenté dans le JSON)

Configuration	Nom dans le JSON
<code>SSIMMetric()</code> — défaut	<code>SSIM[photo]</code>
<code>SSIMMetric(photometric_normalize=False)</code>	<code>SSIM</code>
<code>SSIMMetric(roi='rail_lower')</code>	<code>SSIM[photo+roi]</code>
<code>LPIPSMetric()</code> — défaut	<code>LPIPS[alex+photo]</code>
<code>LPIPSMetric(net='vgg', roi='rail_lower')</code>	<code>LPIPS[vgg+photo+roi]</code>

5. Ce qui n'a pas été modifié (et pourquoi)

`run_full_evaluation.py` implémente déjà correctement :

Élément	Statut
Évaluation conjointe (mêmes v1_frames pour tous les algos)	✓ Déjà implémenté
Baselines (random, linear, offset±k)	✓ Déjà implémenté dans <code>baselines.py</code>
Sensitivity curve (LPIPS/SSIM/cycle vs offset)	✓ Déjà implémenté
Caching des V1 frames (perf)	✓ Déjà implémenté
Cycle consistency (CycleGAN-inspired)	✓ Déjà bon

Les améliorations apportées aux métriques bénéficient automatiquement à `run_full_evaluation.py` sans modification de ce script.

6. Effet attendu sur les résultats

Avec les nouvelles métriques activées par défaut, les scores Plan1 devraient :

Métrique	Avant	Attendu après	Pourquoi
SSIM mean	≈ 0.38	$\approx 0.65 - 0.85$	Élimination du gap photométrique
LPIPS mean	≈ 0.71	$\approx 0.30 - 0.50$	Idem + features perceptuelles
Écart entre AKAZE/BRISK/ORB	$10^2 - 10^3$	$\approx 10^2 - 10^3$	Le signal d'alignement n'est plus noyé
SSIM[photo+roi]	—	encore plus discriminant	Focus sur les rails uniquement

Comment relancer l'évaluation

```
cd Projet/TSV
python combined_method/run_full_evaluation.py Plan1
```

Le JSON de sortie contiendra désormais des entrées `SSIM[photo]` et `LPIPS[alex+photo]` au lieu de `SSIM` et `LPIPS`, ce qui rend explicite le protocole appliqué et évite toute confusion lors de la rédaction de la thèse.

7. Recommandation pour la rédaction

Pour la section évaluation de la thèse, présenter **les deux variantes** :

1. SSIM/LPIPS bruts (anciens) : démontre l'écart photométrique inhérent entre les deux vidéos et justifie pourquoi ces métriques sont insuffisantes telles quelles.
2. SSIM[photo+roi] / LPIPS[vgg+photo+roi] : démontre la qualité réelle de l'alignement géométrique une fois le bruit photométrique retiré.
3. Cycle consistency : reste la métrique la plus discriminante car elle ne dépend pas du tout du contenu visuel (uniquement de la cohérence des mappings).